


# 数学特別講義：機械学習の数理 (note-01)

## 線形回帰モデルとカーネル法

1. カーネル関数を用いた回帰分析の方法
2. 正則化と交差検証法
3. カーネル関数と再生核ヒルベルト空間
4. 平滑化スプラインとカーネル法

# 回帰分析


- データ :  $(\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n), \quad \boldsymbol{x}_i \in \mathbb{R}^d, y_i \in \mathbb{R}.$
- $y$  を  $\boldsymbol{x}$  の関数で説明, 予測.
- 用語の説明
  - \*  $\boldsymbol{x}$  : 入力 (独立変数・説明変数)
  - \*  $y$  : 出力 (従属変数・目的変数)



# 統計モデルの設定

- 単純な統計モデルでは対応できない（かもしれない）  
→ 複雑なモデルを使いたい
- 複雑なモデルを使うと
  - \* 計算が大変
  - \* データへの過剰適合（**overfitting**, 過学習）が心配

# 過剰適合



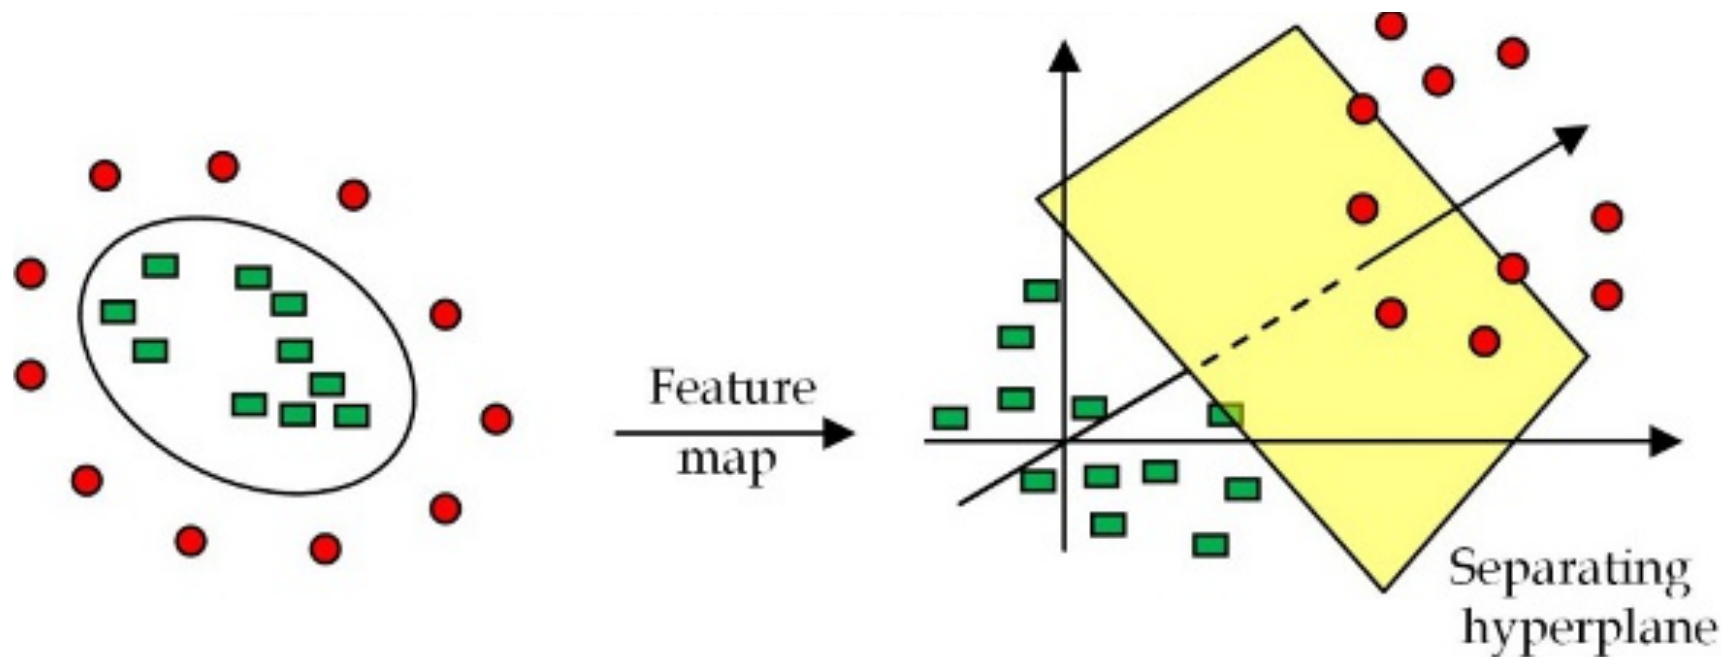
- データ点に適合し過ぎている．予測精度は低い．

# 表現力が高いモデルの構成

- 例：データ  $x \in \mathbb{R}$  を高次元空間  $\mathbb{R}^{1000}$  に非線形変換

$$x \in \mathbb{R} \mapsto \phi(x) \in \mathbb{R}^{1000}$$

- 高次元空間における線形モデルでデータ解析



## 「複雑な統計モデル」を「非線形変換＋線形モデル」で実現

- 適切な変換  $x \mapsto \phi(x)$  を選ぶと、計算量はあまり増えない.
- 過学習には「正則化」&「交差検証法」で対処.


## — カーネル関数を用いた回帰分析の方法 —

- 最小 2 乗法のカーネル表現

## 例：多項式回帰

データの例：

$$(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R} \times \mathbb{R}.$$



- 多項式回帰：  $y = a_0 + a_1x + a_2x^2 + \dots + a_{D-1}x^{D-1} + \varepsilon$   
で当てはめ. ( $\varepsilon$  : ノイズ項)

パラメータ  $(a_0, a_1, \dots, a_{D-1}) \in \mathbb{R}^D$  に関して線形なので線形回帰モデル.



- 多項式回帰の解釈：

- \* データ  $x$  を，以下の  $\phi(x)$  で高次元にマップ.

$$x \in \mathbb{R} \longmapsto \phi(x) = (\phi_0(x), \phi_1(x), \dots, \phi_{D-1}(x))^T \in \mathbb{R}^D,$$
$$\phi_k(x) = x^k, \quad k = 0, 1, \dots, D-1$$

- \* データ  $(\phi(x_1), y_1), \dots, (\phi(x_n), y_n)$  の関数関係を高次元空間  $\mathbb{R}^D$  上の線形モデルで推定：

$$y = a_0\phi_0 + a_1\phi_1 + a_2\phi_2 + \dots + a_{D-1}\phi_{D-1} + \varepsilon$$
$$\longrightarrow \text{推定パラメータ } \hat{\mathbf{a}} = (\hat{a}_0, \dots, \hat{a}_{D-1})^T$$

- \*  $\hat{f}(x) = \hat{\mathbf{a}}^T \phi(x)$  を使って  $x$  に対する  $y$  の値を予測.

## 最小2乗法：デザイン行列を用いた表現

- デザイン行列  $\Phi = (\phi(x_1), \dots, \phi(x_n)) \in \mathbb{R}^{D \times n}$ .
- 観測データ  $\mathbf{y} = (y_1, \dots, y_n)^T$ .

$$\sum_{i=1}^n (y_i - \mathbf{a}^T \phi(x_i))^2 = \|\mathbf{y} - \Phi^T \mathbf{a}\|_2^2 \longrightarrow \mathbf{a} \text{ について最小化}$$

$\text{rank } \Phi = D$  のとき：


$$\text{最小2乗法の解： } \hat{\mathbf{a}} = (\Phi \Phi^T)^{-1} \Phi \mathbf{y}$$

## 最小 2 乗法：カーネル関数を用いた表現

$$\min_{\mathbf{a} \in \mathbb{R}^D} \sum_{i=1}^n (y_i - \mathbf{a}^T \phi(x_i))^2$$

- $\mathbf{a} \in \text{span}\{\phi(x_1), \dots, \phi(x_n)\}$  の範囲で考えれば十分.

直交成分は 2 乗損失に  
影響しない.



- $\mathbf{a} = \sum_{j=1}^n \beta_j \phi(x_j) = \Phi \boldsymbol{\beta}, \quad \boldsymbol{\beta} = (\beta_1, \dots, \beta_n)^T$

→ 2乗誤差に代入

$$\sum_{i=1}^n (y_i - \phi(x_i)^T \mathbf{a})^2 = \|\mathbf{y} - \Phi^T \Phi \boldsymbol{\beta}\|_2^2 \longrightarrow \min_{\boldsymbol{\beta}}$$

極値条件：  $\Phi^T \Phi \underbrace{\Phi \hat{\boldsymbol{\beta}}}_{\hat{\mathbf{a}}} = \Phi^T \Phi \mathbf{y}$

- $k(x, x') := \phi(x)^T \phi(x') \in \mathbb{R}$  とおく (カーネル関数).  
行列  $K \in \mathbb{R}^{n \times n}$  を  $K = \Phi^T \Phi$  とおく.

$$K_{ij} = \phi(x_i)^T \phi(x_j) = k(x_i, x_j),$$

$$\text{極値条件 : } \Phi^T \Phi \Phi^T \Phi \hat{\beta} = \Phi^T \Phi y \iff K^2 \hat{\beta} = K y$$

- 極値条件の式を解く :  $K, y$  から  $\hat{\beta}$  を求める.

$$\hat{f}(x) = \phi(x)^T \underbrace{\sum_{i=1}^n \phi(x_i) \hat{\beta}_i}_{\hat{a}} = \sum_{i=1}^n k(x, x_i) \hat{\beta}_i$$

# グラム行列

データ  $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n$ , 関数  $k(\boldsymbol{x}, \boldsymbol{x}')$ .

$$\text{グラム行列 : } K = \begin{pmatrix} k(\boldsymbol{x}_1, \boldsymbol{x}_1) & \cdots & k(\boldsymbol{x}_1, \boldsymbol{x}_n) \\ \vdots & \ddots & \vdots \\ k(\boldsymbol{x}_n, \boldsymbol{x}_1) & \cdots & k(\boldsymbol{x}_n, \boldsymbol{x}_n) \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

要素で書くと  $K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ .

## グラム行列の性質：非負定値性

$k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{\phi}(\boldsymbol{x})^T \boldsymbol{\phi}(\boldsymbol{x}')$ ,  $\boldsymbol{\Phi} = (\boldsymbol{\phi}(\boldsymbol{x}_1), \dots, \boldsymbol{\phi}(\boldsymbol{x}_n))$  とすると

$$\boldsymbol{K} = \boldsymbol{\Phi}^T \boldsymbol{\Phi}.$$


$\boldsymbol{K}$  は対称非負定値行列

$$\forall \boldsymbol{c} \in \mathbb{R}^n, \quad \boldsymbol{c}^T \boldsymbol{K} \boldsymbol{c} \geq 0, \quad \boldsymbol{K} \succeq \boldsymbol{O} \text{ と書く.}$$

$$\boldsymbol{c}^T \boldsymbol{K} \boldsymbol{c} = \boldsymbol{c}^T \boldsymbol{\Phi}^T \boldsymbol{\Phi} \boldsymbol{c} = \|\boldsymbol{\Phi} \boldsymbol{c}\|_2^2 \geq 0$$

- $k(\boldsymbol{x}, \boldsymbol{x}') = \tanh(1 + \boldsymbol{x}^T \boldsymbol{x}')$ ,  $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$   
カーネル関数でない.

In[4]:= `Plot[Tanh[x], {x, -3, 3}]`



\*  $\boldsymbol{x}_1 = (1, 0, \dots, 0)^T$ ,  $\boldsymbol{x}_2 = (2, 0, \dots, 0)$  とすると

$$K = \begin{pmatrix} k(\boldsymbol{x}_1, \boldsymbol{x}_1) & k(\boldsymbol{x}_1, \boldsymbol{x}_2) \\ k(\boldsymbol{x}_2, \boldsymbol{x}_1) & k(\boldsymbol{x}_2, \boldsymbol{x}_2) \end{pmatrix} \doteq \begin{pmatrix} 0.96403 & 0.99506 \\ 0.99506 & 0.99991 \end{pmatrix}.$$

固有値は 1.97718, -0.0132481. 非負定値でない.



# カーネル回帰分析の方法

- データ :  $(\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n), \quad \boldsymbol{x}_i \in \mathbb{R}^d, y \in \mathbb{R}.$
- 統計モデル :  $y = \boldsymbol{a}^T \boldsymbol{\phi}(\boldsymbol{x}) + \varepsilon$

## カーネル回帰分析

1. カーネル関数  $k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{\phi}(\boldsymbol{x})^T \boldsymbol{\phi}(\boldsymbol{x}')$  を定義.
2. グラム行列  $K, K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j), i, j = 1, \dots, n$  を計算.
3.  $K^2 \hat{\boldsymbol{\beta}} = K \boldsymbol{y}$  を  $\hat{\boldsymbol{\beta}}$  について解く.
4. 回帰関数  $\hat{f}(x) = \sum_{i=1}^n k(\boldsymbol{x}, \boldsymbol{x}_i) \hat{\beta}_i$

以下は同じ推定：

- 線形回帰モデル  $y = a_1\phi_1(\boldsymbol{x}) + \cdots + a_D\phi_D(\boldsymbol{x}) + \varepsilon$  で最小2乗推定.
- カーネル関数  $k(\boldsymbol{x}, \boldsymbol{x}') = \phi(\boldsymbol{x})^T \phi(\boldsymbol{x}')$  でカーネル回帰.

$\phi(x)$  ではなく  $k(x, x')$  を使う理由？

# カーネル回帰分析の特徴

$k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{\phi}(\boldsymbol{x})^T \boldsymbol{\phi}(\boldsymbol{x}')$  だけから推定量を計算できる.

- 写像先  $\mathbb{R}^D$  が無限次元 ( $D = \infty$ ) でも,  $k(\boldsymbol{x}, \boldsymbol{x}')$  が簡単に計算できれば **O.K.**

例：ガウシアンカーネル (後述)

- 1次式モデル  $y = \boldsymbol{a}^T \boldsymbol{x} + \varepsilon$  とほぼ同じ計算手順. 表現力が大幅アップ!

カーネル関数の例：  $\boldsymbol{x} \in \mathbb{R}^d \mapsto \boldsymbol{\phi}(\boldsymbol{x}) \in \mathbb{R}^D$ .

- 線形カーネル：  $D = d$

$$k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{x}^T \boldsymbol{x}', \quad (\boldsymbol{\phi}(\boldsymbol{x}) = \boldsymbol{x})$$

$$\text{統計モデル： } y = \boldsymbol{a}^T \boldsymbol{\phi}(\boldsymbol{x}) + \varepsilon = \boldsymbol{a}^T \boldsymbol{x} + \varepsilon$$

- 多項式カーネル：  $D = \frac{(\gamma+d)!}{\gamma! d!}$

$$k(\mathbf{x}, \mathbf{x}') = (1 + \mathbf{x}^T \mathbf{x}')^\gamma, \quad \gamma = 1, 2, 3, \dots$$

統計モデル：  $y = \mathbf{a}^T \phi(\mathbf{x}) + \varepsilon$ .

$\phi(\mathbf{x})$ ：  $\gamma$  次以下のすべての単項式からなるベクトル.

$d = 2, \gamma = 2$  のとき

$$\phi(\mathbf{x}) = (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1x_2)^T.$$

$$\begin{aligned} \phi(\mathbf{x})^T \phi(\mathbf{z}) &= 1 + 2x_1z_1 + 2x_2z_2 + x_1^2z_1^2 + x_2^2z_2^2 + 2x_1x_2z_1z_2 \\ &= (1 + x_1z_1 + x_2z_2)^2 \end{aligned}$$

- ガウシアンカーネル :  $D = \infty$

$$k(\boldsymbol{x}, \boldsymbol{x}') = \exp\{-\sigma \|\boldsymbol{x} - \boldsymbol{x}'\|_2^2\}, \quad \sigma > 0$$

$d = 1, \sigma = 1$  のとき :

$$\boldsymbol{\phi}(x) = (\phi_0(x), \phi_1(x), \phi_2(x), \dots),$$

$$\phi_j(x) = \frac{x^j e^{-x^2/2}}{\sqrt{j!}}, \quad x \in \mathbb{R}$$

- R言語によるカーネル回帰

```
> # not run. x: データ行列 (サイズ = サンプル数 * 次元)
>
> # 多項式カーネル (degree=2)
> K <- kernelMatrix(polydot(degree=2), x)
>
> # ガウシアンカーネル (sigma=3)
> K <- kernelMatrix(rbfdot(sigma=3), x)
```

- 初期設定

```
> library(kernlab)    #ライブラリ読込  
> deg <- 6            #多項式カーネルの次数を設定  
> n <- 100            #データ数 n=100
```

- データの生成

```
> x <- matrix(runif(n,min=-3,max=3))  
> y <- sin(pi*x)/x+rnorm(n,sd=0.4)
```

- 多項式カーネル (polydot) のグラム行列の生成

```
> K <- kernelMatrix(polydot(degree=deg),x)
```



- 推定量の計算（2乗誤差の最小化）

- > # 2乗誤差とその勾配

- > f <- function(z) sum((K%\*%z-y)^2)

- > g <- function(z) as.vector(2\*K%\*%(K%\*%z-y))

- > # 2乗誤差の最小化

- > beta <- optim(rep(0,n),f,g,method="BFGS")\$par

- 予測値の計算

- > px <- matrix(seq(-3,3,1=300)) #予測点

- > # px 上での y の予測値

- > py<-kernelMult(polydot(degree=deg),px,x,beta)


補足：f<-kernelMult(kernel,x1,x2,beta) は

$$f_i = \sum_{j=1}^n k(x1_i, x2_j) \beta_j \text{ を計算.}$$


- R-code : 2乗損失の最小化でパラメータ  $\hat{\beta}$  を計算.  
(`beta <- optim(...)` の行)
- 一般化逆行列 (`MASS::ginv`) でも計算可だが数値的に不安定.

多項式カーネルによる回帰分析の結果 :


```
> plot(x,y,lwd=3);lines(px,py,lwd=4,col=2) #プロット
```



degree= 2



degree= 6




degree= 9

## — データへの過剰適合と正則化 —


# データへの過剰適合（過学習）

- 単純なモデルでは対応できなさそうなデータの解析  
→ 自由度の大きなモデルを使う.
- モデルの自由度が大きすぎてもうまくいかない.


自由度：小



自由度：中



自由度：大



# 正則化：モデルの自由度を調整

考え方：自由度の大きいモデル + パラメータを適切に制約

データ：  $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$

線形回帰モデル：  $y = \mathbf{a}^T \phi(\mathbf{x}) + b + \varepsilon$

$$\iff y = \sum_{j=1}^n \beta_j k(\mathbf{x}_j, \mathbf{x}) + b + \varepsilon, \quad \mathbf{a} = \sum_{j=1}^n \beta_j \phi(\mathbf{x}_j)$$

正則化：  $\|\mathbf{a}\|_2^2 = \|\sum_{j=1}^n \beta_j \phi(\mathbf{x}_j)\|_2^2$  の大きさを制約する.

$$\|\mathbf{a}\|_2^2 = \sum_{i,j} \beta_i \beta_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) = \sum_{i,j} \beta_i \beta_j k(\mathbf{x}_i, \mathbf{x}_j)$$

正則化パラメータ  $\lambda > 0$ .


$$\min_{\boldsymbol{\beta}, b} \sum_{i=1}^n \left\{ y_i - \left( \sum_{j=1}^n \beta_j k(\mathbf{x}_j, \mathbf{x}_i) + b \right) \right\}^2 + \lambda \sum_{i,j} \beta_i \beta_j k(\mathbf{x}_i, \mathbf{x}_j)$$

正則化項

$$\implies \text{最適解 } \hat{\beta}_1, \dots, \hat{\beta}_n, \hat{b}. \quad \hat{f}(\mathbf{x}) = \sum_{j=1}^n \hat{\beta}_j k(\mathbf{x}_j, \mathbf{x}) + \hat{b}$$


ベクトル・行列で表すと

$$\min_{\boldsymbol{\beta}, b} \|\mathbf{y} - (K\boldsymbol{\beta} + b\mathbf{1})\|_2^2 + \lambda \boldsymbol{\beta}^T K \boldsymbol{\beta}$$




正則化パラメータ  $\lambda > 0$ .

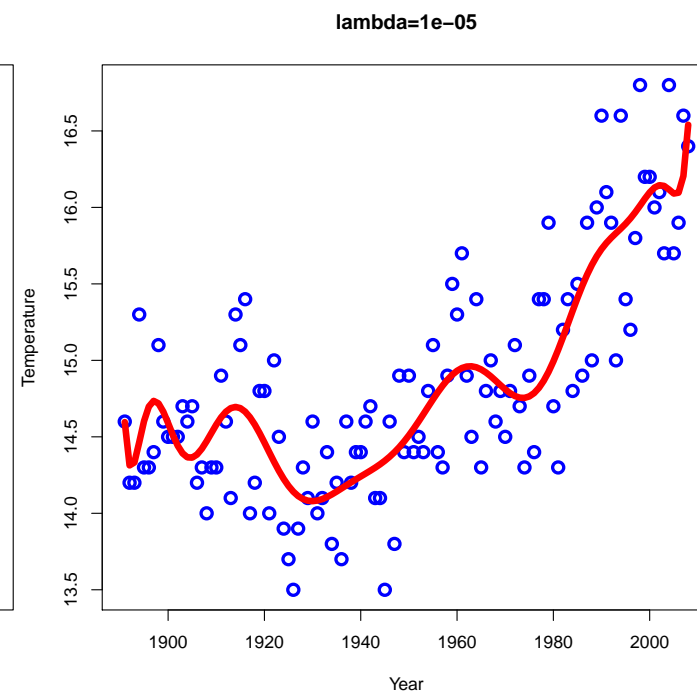
$\lambda$  : 大



$\lambda$  : 中



$\lambda$  : 小



小さい ← モデル自由度 (表現力) → 大きい



- 極値条件 (凸最適化なので大域解)

$$\min_{\boldsymbol{\beta}, b} \|\mathbf{y} - K\boldsymbol{\beta} - b\mathbf{1}\|_2^2 + \lambda\boldsymbol{\beta}^T K\boldsymbol{\beta}$$

$$\Rightarrow \begin{pmatrix} \mathbf{1} & K + \lambda I \\ n & \mathbf{1}^T K \end{pmatrix} \begin{pmatrix} \hat{b} \\ \hat{\boldsymbol{\beta}} \end{pmatrix} = \begin{pmatrix} \mathbf{y} \\ \mathbf{1}^T \mathbf{y} \end{pmatrix}, \quad K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j),$$

$$\hat{f}(\mathbf{x}) = \sum_{i=1}^n \hat{\beta}_i k(\mathbf{x}_i, \mathbf{x}) + \hat{b}$$

- カーネル関数  $k(\mathbf{x}, \mathbf{x}')$  だけから計算できる.  
( $\phi(\mathbf{x})$  は単体では現れない)

# R言語による正則化付きカーネル回帰

- 初期設定

```
> library(kernlab) # パッケージ読込
> sig <- 3; l <- 1; # パラメータ: sigma,  $\lambda$ 
> n <- 100          # データ生成: データ数 n=100
> x <- matrix(runif(n,min=-4,max=4))
> y <- sin(pi*x)/x + rnorm(n,sd=0.5)
```

- ガウシアンカーネル (rbfdot) のグラム行列

```
> K <- kernelMatrix(rbfdot(sigma=sig),x)
```

- 推定量の計算：2乗誤差最小 [optim() 関数]


```
> f <- function(z){w <- z[-(n+1)];  
+   (sum((cbind(K,1)%*%z-y)^2)+1*w%*%K%*%w)/2}  
> g <- function(z){w <- z[-(n+1)];  
+   rbind(K,1)%*%(cbind(K,1)%*%z-y)+c(1*K%*%w,0)}  
> s <- optim(rep(0,n+1),f,g,method="BFGS")$par  
> beta <- s[1:n]; b <- s[n+1]
```

- 予測

```
> px <- seq(-4,4,l=100) # 予測点  
> py <- kernelMult(rbfdot(sigma=sig),px,x,beta)+b  
> plot(x,y);lines(px,py,lwd=4,col=2) #プロット
```

## データ点と推定結果の プロット

- ガウシアンカーネルの  
カーネルパラメータ： $\sigma = 3$
- 正則化パラメータ： $\lambda = 1$



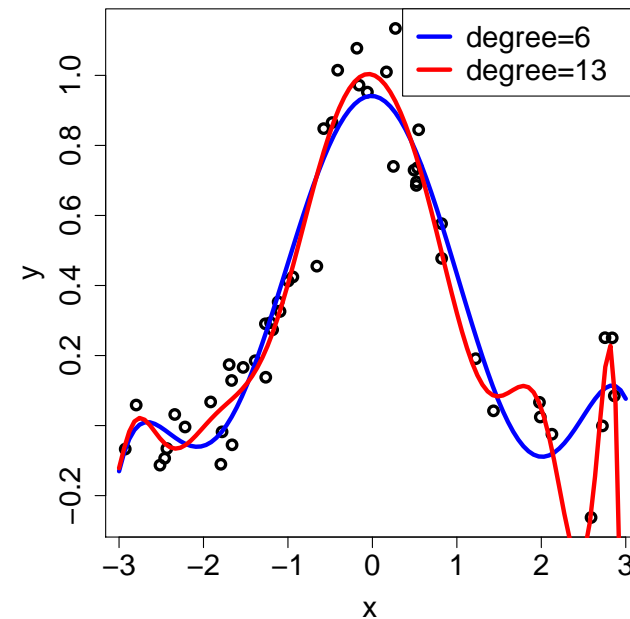

## モデル選択：学習誤差と予測誤差

- 学習データ： $(\boldsymbol{x}_1, y_1), \dots, (\boldsymbol{x}_n, y_n) \sim_{i.i.d.} P$
- 学習データから推定された回帰関数  $\hat{f}(x)$

$$\text{学習誤差} : \frac{1}{n} \sum_{i=1}^n (\hat{f}(\boldsymbol{x}_i) - y_i)^2 \quad (\text{データから計算可能})$$

$$\text{予測誤差} : \mathbb{E}_{(\boldsymbol{x}, y) \sim P} [(\hat{f}(\boldsymbol{x}) - y)^2] \quad (\text{データだけでは分からない})$$

## 多項式回帰



## 過学習

- 多項式の次数高いと . . .

- \* 学習誤差は小さくなる
- \* 予測誤差は大きくなる

→ モデル選択：モデルの自由度を適切に設定する.

# カーネル法におけるモデル選択

- カーネル回帰  $\hat{f}(x)$  の自由度を調整するパラメータ：

- ＊ カーネルパラメータ：kpar

- 多項式カーネルの  $\gamma = 1, 2, 3, \dots$
- ガウシアンカーネルの  $\sigma > 0$

- ＊ 正則化パラメータ： $\lambda > 0$ ,  $\text{loss}(\beta) + \lambda \beta^T K \beta$

- これらを適切に定める.


- いろいろな  $\text{mpar} = (\text{kpar}, \lambda)$  について . . .
  - \*  $\text{mpar}$  に対する回帰関数 :  $\hat{f}_{\text{mpar}}(\boldsymbol{x})$
  - \* データから  $\hat{f}_{\text{mpar}}(\boldsymbol{x})$  の予測誤差を推定  $\longrightarrow \hat{e}_{\text{mpar}}$
- $\hat{e}_{\text{mpar}}$  を最小にするモデルパラメータ  $\text{mpar}$  を選択.

$\hat{e}_{\text{mpar}}$  の計算法 : ( $K$  重) 交差検証法



# $K$ 重交差検証法 (K-fold cross validation)

- データを  $K$  個のグループに分割



- 予測誤差の推定値  $\hat{e}_{\text{mpar}}$  :  $\text{error}_1, \dots, \text{error}_K$  の平均.

1. データ  $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$  をほぼ同じサイズの  $K$  個のグループ  $\mathcal{D}_1, \dots, \mathcal{D}_K$  に分割.  $\mathcal{D}^{(k)}$  を以下のように定める.

$$\mathcal{D}_i \cap \mathcal{D}_j = \emptyset \quad (i \neq j), \quad \bigcup_{i=1}^K \mathcal{D}_i = \mathcal{D}, \quad \mathcal{D}^{(k)} := \mathcal{D} \setminus \mathcal{D}_k = \bigcup_{i \neq k} \mathcal{D}_i.$$

2.  $\ell = 1, \dots, K$  に対して以下を繰り返す.

(a)  $\mathcal{D}^{(\ell)}$  を用いてモデルパラメータ  $\text{mpar}$  の回帰関数を学習:  $\hat{f}_\ell(\mathbf{x})$

(b)  $\mathcal{D}_\ell$  に対する  $\hat{f}_\ell(\mathbf{x})$  の誤差を  $e_\ell$  とする.


$$e_\ell := \frac{1}{|\mathcal{D}_\ell|} \sum_{(\mathbf{x}, y) \in \mathcal{D}_\ell} (y - \hat{f}_\ell(\mathbf{x}))^2$$

(推定に使っていないデータに対する予測誤差)


3. 出力: 予測誤差の推定値  $\hat{e}_{\text{mpar}} = \frac{1}{K} \sum_{\ell=1}^K e_\ell$ .

## 推定結果：ガウシアンカーネル


- カーネルパラメータ  $\sigma$ ：交差検証法で決定
- 正則化パラメータ： $\lambda = 1$  と固定



$$(\sigma, \lambda) = (0.1, 1)$$

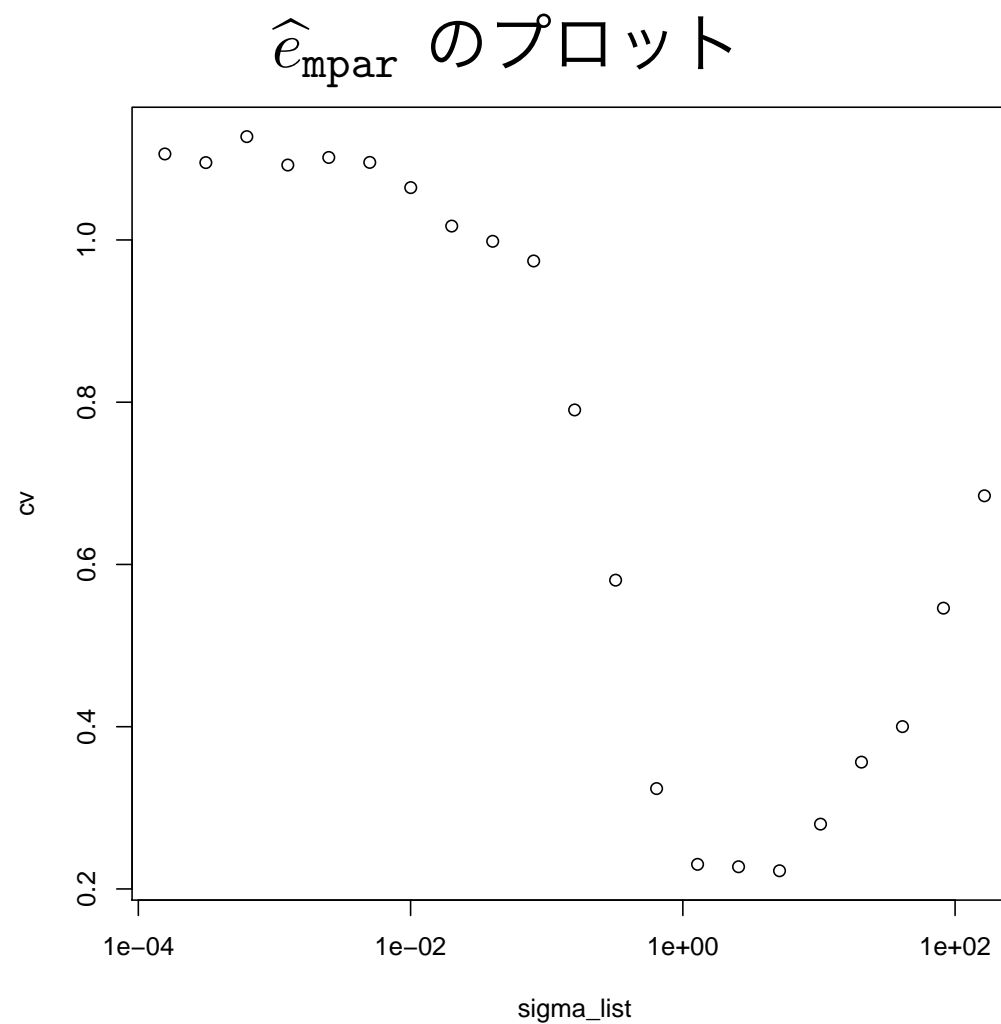


$$(\sigma, \lambda) = (2.5, 1)$$



$$(\sigma, \lambda) = (30, 1)$$

$K = 5$ の交差検証法.  
 $\sigma \cong 2.5$  で  $\hat{e}_{\text{mpar}}$  が最小.



# ヒューリスティクス

- $K$ -交差検証法：計算コストが大きい.
  - \*  $K$  回学習  $\implies$  ひとつの  $\text{mpar}$  に対する  $\hat{e}_{\text{mpar}}$  が求まる.
  - \* モデルパラメータの選択：  $K$  回  $\times$   $\text{mpar}$  の候補数
- モデルパラメータが2次元以上の場合
  - \* いくつかのパラメータ値を適当な値に固定.  
残りのパラメータを交差検証法で決める.

# ガウシアンカーネルの $\sigma$ の選び方

ガウシアンカーネル：

$$k(\mathbf{x}, \mathbf{x}') = \exp\{-\sigma \|\mathbf{x} - \mathbf{x}'\|_2^2\}$$

- 数値計算の安定性のため,  $\sigma \|\mathbf{x}_i - \mathbf{x}_j\|_2^2$  が「ほどほどの値」を取るようにする.


$$d^2 := \text{median}\{\|\mathbf{x}_i - \mathbf{x}_j\|_2^2 \mid i < j\} \quad (\text{中央値}),$$

$$\sigma = 1/d^2$$


$\implies \sigma \|\mathbf{x}_i - \mathbf{x}_j\|_2^2$  は 1 のまわりに分布.

# 推定結果


- カーネルパラメータ  $\sigma$  : ヒューリスティクス
- 正則化パラメータ  $\lambda$  : いろいろ変える.



$$(\sigma, \lambda) = (0.98, 0.1^5)$$




$$(\sigma, \lambda) = (0.98, 0.78)$$



$$(\sigma, \lambda) = (0.98, 10)$$

- $\hat{e}_{\text{mpar}}$  のプロット



- $\sigma = 0.984$ ,  $\lambda = 0.781$  が選択された.



# カーネル関数と再生核ヒルベルト空間

- (非負定値) カーネル関数
- 再生核ヒルベルト空間
- 表現定理

カーネル法による学習：ある関数空間 (再生核ヒルベルト空間) を統計モデルに設定することと等価.

参考文献：

- 福水, カーネル法入門, 朝倉書店
- 赤穂, カーネル多変量解析, 岩波書店

**Definition 1** ((非負定値)カーネル関数).

集合  $\mathcal{X}$  (例えば  $\mathbb{R}^d$  の部分集合) に対して, 以下を満たす関数  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  を (非負定値)カーネル関数 という:

1. 対称性:  $k(x, x') = k(x', x), \quad \forall x, x' \in \mathcal{X}$

2. 非負定値性:  $\forall n \in \mathbb{N}, \forall x_1, \dots, x_n \in \mathcal{X}$

$$n \times n \text{ 対称行列 } K = \begin{pmatrix} k(x_1, x_1) & \cdots & k(x_1, x_n) \\ \vdots & \ddots & \vdots \\ k(x_n, x_1) & \cdots & k(x_n, x_n) \end{pmatrix}$$

は非負定値行列

$$\left( \iff \sum_{i,j=1}^n c_i c_j k(x_i, x_j) \geq 0, \quad \forall c_1, \dots, c_n \in \mathbb{R} \right)$$

## 復習：非負定値行列

非負定値 (対称) 行列  $A \in \mathbb{R}^{n \times n}$ . 以下の **1,2** は同値

1.  $\forall \mathbf{c} \in \mathbb{R}^n, \mathbf{c}^T A \mathbf{c} \geq 0.$

2.  $A$  の固有値は全て非負. (対称行列なので固有値は実数).

$A$  の対角化：固有値  $\lambda_i \geq 0$ , 固有ベクトル  $\mathbf{u}_i \in \mathbb{R}^n$

$$A \mathbf{u}_i = \lambda_i \mathbf{u}_i, \quad i = 1, \dots, n, \quad \mathbf{u}_i^T \mathbf{u}_j = \delta_{ij},$$

スペクトル分解： 
$$A = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T.$$

$k, k_1, k_2, \dots$ , がすべてカーネル関数のとき

1.  $\phi : \mathcal{X} \rightarrow \mathbb{R}^D$  に対して  $k(x, x') = \phi(x)^T \phi(x')$  はカーネル関数
2. 非負定数  $a, b \geq 0$  に対して  $a + b \cdot k(x, x')$  はカーネル関数
3.  $k_1(x, x') + k_2(x, x')$  はカーネル関数
4.  $k_1(x, x')k_2(x, x')$  はカーネル関数
5.  $\bar{k}(x, x') = \lim_{m \rightarrow \infty} k_m(x, x')$  (各点収束) が存在するなら  $\bar{k}$  はカーネル関数.

**proof of 4.:**  $n$ 次非負定値行列  $K_1, K_2 \succeq O$  に対して

$$K_{ij} = (K_1)_{ij}(K_2)_{ij}$$

とする.  $K \succeq O$ を示す. スペクトル分解  $K_1 = \sum_{r=1}^n \lambda_r \mathbf{x}_r \mathbf{x}_r^T$  に対して

$$\begin{aligned} \sum_{i,j} c_i c_j K_{ij} &= \sum_{i,j} c_i c_j (K_1)_{ij} (K_2)_{ij} \\ &= \sum_{i,j} c_i c_j \sum_{r=1}^n \lambda_r x_{ri} x_{rj} (K_2)_{ij} \\ &= \sum_{r=1}^n \lambda_r \sum_{i,j} (c_i x_{ri}) (c_j x_{rj}) (K_2)_{ij} \geq 0 \end{aligned}$$

**Theorem 1.** ガウスカーネルはカーネル関数である.

**Gaussian kernel:**  $\boldsymbol{x} \in \mathbb{R}^d$  に対して

$$k(\boldsymbol{x}, \boldsymbol{x}') = \exp\{-\sigma \|\boldsymbol{x} - \boldsymbol{x}'\|_2^2\}, \quad (\sigma > 0)$$

は実用上よく利用される. **Gaussian kernel** がカーネル関数の定義を満たすことを示す.

*Proof.* 対称性は明らか. 非負定値性を示す.

$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$ ,  $c_1, \dots, c_n \in \mathbb{R}$  に対して  $d_i = c_i \exp\{-\sigma \|\mathbf{x}_i\|_2^2\}$  とすると

$$\sum_{i,j=1}^n c_i c_j \exp\{-\sigma \|\mathbf{x}_i - \mathbf{x}_j\|_2^2\} = \sum_{i,j=1}^n d_i d_j \exp\{2\sigma \mathbf{x}_i^T \mathbf{x}_j\}.$$

ただし  $d_i = c_i \exp\{-\sigma \|\mathbf{x}_i\|_2^2\}$ . したがって,  $k_1(\mathbf{x}, \mathbf{x}') = \exp\{2\sigma \mathbf{x}^T \mathbf{x}'\}$  がカーネル関数であること示せばよい.  $e^z = 1 + z + z^2/2 + \dots + z^n/n! + \dots$  より

$$\begin{aligned} & \exp\{2\sigma \mathbf{x}^T \mathbf{x}'\} \\ &= 1 + 2\sigma \mathbf{x}^T \mathbf{x}' + (2\sigma)^2 (\mathbf{x}^T \mathbf{x}')^2 / 2 + \dots + (2\sigma)^n (\mathbf{x}^T \mathbf{x}')^n / n! + \dots \end{aligned}$$

上の各項  $(2\sigma)^n (\mathbf{x}^T \mathbf{x}')^n / n!$  はカーネル関数であり, その総和が  $k_1(\mathbf{x}, \mathbf{x}')$  に各点収束するので,  $k_1$  もカーネル関数である. ■

# カーネル関数から生成される関数空間

- カーネル関数から生成される線形空間

$$\mathcal{H}_0 := \left\{ f(\cdot) = \sum_{j=1}^m \gamma_j k(x_j, \cdot) \mid m \in \mathbb{N}, x_j \in \mathcal{X}, \gamma_j \in \mathbb{R} \right\}$$

$\mathcal{H}_0$  上に  $\langle k(x, \cdot), k(x', \cdot) \rangle = k(x, x')$  を満たす双線型形式を定義  
→ 実は内積.



## 補足

- $\langle f, g \rangle$ ,  $f, g \in \mathcal{H}_0$  が  $f, g$  の表し方に依らないこと :

$$f(x) = \sum_{i=1}^n \alpha_i k(x_i, x), \quad g(x) = \sum_{j=1}^m \beta_j k(y_j, x) \quad \text{のとき}$$

$$\begin{aligned} \langle f, g \rangle &= \sum_{i,j} \alpha_i \beta_j \langle k(x_i, \cdot), k(y_j, \cdot) \rangle \\ &= \sum_{i,j} \alpha_i \beta_j k(x_i, y_j) = \sum_j \beta_j f(y_j) = \sum_i \alpha_i g(x_i) \end{aligned}$$

よって  $f, g$  の表し方に依らない.

**Theorem 2.** 以下の等式が成り立つ：

$$[\text{再生性}] : \quad \langle f, k(z, \cdot) \rangle = f(z) \quad f \in \mathcal{H}_0, \quad z \in \mathcal{X}$$

*Proof.*  $f(x) = \sum_{j=1}^m \gamma_j k(x_j, x)$  とすると

$$\langle f, k(z, \cdot) \rangle = \sum_{j=1}^m \gamma_j \langle k(x_j, \cdot), k(z, \cdot) \rangle = \sum_{j=1}^m \gamma_j k(x_j, z) = f(z)$$



**Theorem 3.**  $\langle f, g \rangle$  は  $\mathcal{H}_0$  上の内積である.

*Proof.* 双線形性, 対称性は **O.K.** 以下を証明する:

$$\langle f, f \rangle \geq 0, \quad \langle f, f \rangle = 0 \iff f = 0.$$

グラム行列の非負定値性より  $f(\cdot) = \sum_{i=1}^n \gamma_i k(x_i, \cdot)$  に対して

$$\langle f, f \rangle = \sum_{i,j=1}^n \gamma_i \gamma_j \langle k(x_i, \cdot), k(x_j, \cdot) \rangle = \sum_{i,j=1}^n \gamma_i \gamma_j k(x_i, x_j) \geq 0.$$

$f = 0$  なら  $\langle f, f \rangle = 0$  は明らか. 逆を示す.  $\langle f, f \rangle \geq 0$  を使うとコーシー・シュワルツの不等式が成り立つ (注).

$$|f(x)|^2 = |\langle f, k(x, \cdot) \rangle|^2 \leq \langle f, f \rangle \langle k(x, \cdot), k(x, \cdot) \rangle = \langle f, f \rangle k(x, x)$$

よって  $\langle f, f \rangle = 0$  なら任意の  $x \in \mathcal{X}$  で  $|f(x)| = 0$  よって  $f = 0$  となる. ■

(注)  $\langle f, g \rangle$  が対称・双線形で  $\langle f, f \rangle \geq 0$  を満たすなら  
コーシー・シュワルツの不等式

$$|\langle f, g \rangle|^2 \leq \langle f, f \rangle \langle g, g \rangle \quad (1)$$

が成り立つ. 条件  $[\langle f, f \rangle = 0 \Leftrightarrow f = 0]$  は(1) を示すのに必要ない.

## ヒルベルト空間 $\mathcal{H}_k$ の構成

1.  $\mathcal{H}_0$  を完備化  $\rightarrow$  ヒルベルト空間 (完備な内積空間)  $\tilde{\mathcal{H}}$ .  
完備: コーシー列は収束する.  $\mathcal{H}_0$  のコーシー列の集合を,

$$\text{同値関係 } \{f_n\} \sim \{g_n\} \Leftrightarrow \lim_{n \rightarrow \infty} |f_n - g_n| = 0$$

で割る.

i.e.  $\tilde{\mathcal{H}} = \{\{f_n\} \subset \mathcal{H}_0 : \{f_n\} \text{ はコーシー列}\} / \sim$ . 内積も自然に定義される.

2.  $\tilde{\mathcal{H}}$  の要素  $[\{f_n\}] \Leftrightarrow$  関数  $f(x) = \lim_{n \rightarrow \infty} f_n(x)$  と対応  
 $\Rightarrow$  ヒルベルト空間  $(\mathcal{H}_k, \langle \cdot, \cdot \rangle)$ ,  $\mathcal{H}_k \subset \mathbb{R}^{\mathcal{X}}$ ,  $\|f\| = \sqrt{\langle f, f \rangle}$ .

- $\mathcal{H}_k$  で収束性の議論ができる.
- $\mathcal{H}_k$  の再生性 :  $\forall x \in \mathcal{X}, \forall f \in \mathcal{H}_k, \langle f, k(x, \cdot) \rangle = f(x)$
- $\infty$ -ノルムとの関連 :  $f \in \mathcal{H}$  に対して

$$\|f\|_{\infty} \leq \|f\| \sup_{x \in \mathcal{X}} \sqrt{k(x, x)}$$

*Proof.*

$$\begin{aligned} \|f\|_{\infty} &= \sup_{x \in \mathcal{X}} |f(x)| = \sup_{x \in \mathcal{X}} |\langle f, k(x, \cdot) \rangle| \leq \sup_{x \in \mathcal{X}} \|f\| \|k(x, \cdot)\| \\ &= \|f\| \sup_{x \in \mathcal{X}} \sqrt{k(x, x)} \end{aligned}$$



カーネル関数とヒルベルト空間との対応：

定義：  $(\mathcal{H}, \langle \cdot, \cdot \rangle)$ ,  $\mathcal{H} \subset \mathbb{R}^{\mathcal{X}}$  をヒルベルト空間とする. 次の (i)(ii) を満たす  $\bar{k}(x, x')$  が存在するとき,  $\mathcal{H}$  を 再生核ヒルベルト空間 **(RKHS)** といい,  $\bar{k}$  を 再生核 という.

$$(i) \quad \forall x \in \mathcal{X}, \bar{k}(x, \cdot) \in \mathcal{H}$$

$$(ii) \quad \forall x \in \mathcal{X}, \forall f \in \mathcal{H}, \quad \langle f, \bar{k}(x, \cdot) \rangle = f(x)$$

**Theorem 4.** カーネル関数  $\Longleftrightarrow$  RKHS (対一対応).  $k \leftrightarrow \mathcal{H}_k$ .

*Proof.* 1.  $\Rightarrow$ ) カーネル関数  $k \rightarrow$  Hilbert空間  $\mathcal{H}_k$ . このとき  $k$  は  $\mathcal{H}_k$  の再生核. よって  $\mathcal{H}_k$  は RKHS.

$\Leftarrow$ ) RKHS  $\mathcal{H}_1 = \mathcal{H}_2$  (内積も  $\langle \cdot, \cdot \rangle_1 = \langle \cdot, \cdot \rangle_2$ ), 再生核を  $k_1, k_2$  とする. このとき  $k_1 = k_2$ . なぜなら

$$\begin{aligned} k_1(x, y) &= \langle k_1(x, \cdot), k_2(y, \cdot) \rangle = \langle k_2(y, \cdot), k_1(x, \cdot) \rangle \\ &= k_2(y, x) = k_2(x, y) \end{aligned}$$

再生核  $k$  はカーネル関数.

対称性:  $k(x, x') = \langle k(x, \cdot), k(x', \cdot) \rangle = \langle k(x', \cdot), k(x, \cdot) \rangle = k(x', x)$ .

グラム行列の非負定値性:  $f(\cdot) = \sum_i c_i k(x_i, \cdot)$  と  $\langle f, f \rangle \geq 0$  から分かる. ■



## フーリエ変換による **RKHS** の表現

$$\text{フーリエ変換} : f(x) \longmapsto \hat{f}(t) = \mathcal{F}[f](t) = \frac{1}{2\pi} \int_{\mathbb{R}} f(x) e^{-\sqrt{-1}xt} dx,$$

$$\text{フーリエ逆変換} : \hat{f}(t) \longmapsto f(x) = \mathcal{F}^{-1}[\hat{f}](x) = \int_{\mathbb{R}} \hat{f}(t) e^{\sqrt{-1}tx} dt$$

$f \in L_2(\mathbb{R})$  なら  $\mathcal{F}^{-1}[\hat{f}] = f$  (適切に定義すれば)

- $\rho \in L_1(\mathbb{R}) \cap C(\mathbb{R})$ ,  $\rho > 0$ . 次の  $\mathcal{H}$  は **RKHS**.

$$\mathcal{H} = \left\{ f \in L_2(\mathbb{R}) \mid \int |\hat{f}(t)|^2 / \rho(t) dt < \infty \right\},$$

$$\text{内積: } \langle f, g \rangle = \int \frac{\hat{f}(t) \overline{\hat{g}(t)}}{\rho(t)} dt.$$

- 対応するカーネル:

$$k(x, y) = k_x(y) = \int_{\mathbb{R}} e^{-\sqrt{-1}t(x-y)} \rho(t) dt = \mathcal{F}^{-1}[e^{-\sqrt{-1}tx} \rho(t)](y),$$

$$\hat{k}_x(t) = e^{-\sqrt{-1}tx} \rho(t).$$

再生性：  $\langle f, k_x \rangle = \int \frac{\widehat{f}(t) \overline{\widehat{k}_x(t)}}{\rho(t)} dt = \int \widehat{f}(t) e^{\sqrt{-1}tx} dt = f(x).$

- ガウスカーネル：  $\rho(t) = \frac{\sigma}{2\pi} e^{-\sigma^2 t^2/2} \Rightarrow k(x, y) = e^{-(x-y)^2/(2\sigma^2)},$

$$\mathcal{H} = \left\{ f \in L^2(\mathbb{R}, dx) \mid \int |\widehat{f}(t)|^2 e^{\sigma^2 t^2/2} dt < \infty \right\}$$

- ラプラスカーネル：

$$\rho(t) = \frac{1}{2\pi} \frac{1}{t^2 + \beta^2} \Rightarrow k(x, y) = \frac{1}{2\beta} e^{-\beta|x-y|},$$

$$\mathcal{H} = \left\{ f \in L^2(\mathbb{R}, dx) \mid \int |\widehat{f}(t)|^2 (t^2 + \beta^2) dt < \infty \right\}$$

上記の  $\mathcal{H}$ ：コンパクト集合  $\mathcal{X}$  への制限  $\{f|_{\mathcal{X}} \mid f \in \mathcal{H}\}$  は  $C(\mathcal{X})$  で稠密 (**universal kernel**).

1. カーネル関数  $k(x, x') \mapsto \mathbf{RKHS} \mathcal{H}_k$ .

2. データから関数  $f(x) \in \mathcal{H}_k$  を推定

- カーネル関数  $k$  を用いて学習：統計モデルは  $\mathbf{RKHS} \mathcal{H}_k$ 
  - \*  $\mathcal{H}_k$ ：統計的性質 (収束性など) を調べるのに役立つ.
  - \* アルゴリズムは (大抵)  $\mathcal{H}_0$  で記述可能

**Theorem 5** (表現定理).

$\lambda > 0, x_1, \dots, x_n \in \mathcal{X}$  とする. 最適化問題

$$\min_{f, b} L(f(x_1), \dots, f(x_n), b) + \lambda \|f\|^2, \quad f \in \mathcal{H}_k, \quad b \in \mathbb{R}$$

の最適解は  $\text{span}\{k(x_1, \cdot), \dots, k(x_n, \cdot)\}$  に含まれる.

**Remark** . 表現定理より,  $f(x) = \sum_{i=1}^n \alpha_i k(x_i, x)$  として  $\alpha_i$  を求めればよい.  
 $\mathcal{H}_k$  の次元が無限でも, 有限次元最適化問題を解けばよい.

- カーネル回帰分析で同様の議論をした.

*Proof.*  $\mathcal{H}$  のなかで関数  $k(x_1, \cdot), \dots, k(x_n, \cdot)$  で張られる部分空間を  $\mathcal{M}$  とする：  
$$\mathcal{M} = \left\{ \sum_{i=1}^n \gamma_i k(x_i, \cdot) \mid \gamma_1, \dots, \gamma_n \in \mathbb{R} \right\}.$$

関数  $f \in \mathcal{H}_k$  を  $\mathcal{M}$  の成分と直交成分  $\mathcal{M}^\perp$  に分解する：

$$f = g + h, \quad g \in \mathcal{M}, \quad h \in \mathcal{M}^\perp \quad (\text{Hilbert 空間の射影定理})$$

このとき次式がなりたつ：

$$\begin{aligned} \|f\|_{\mathcal{H}}^2 &= \langle g + h, g + h \rangle = \langle g, g \rangle + \langle h, h \rangle + \langle g, h \rangle + \langle h, g \rangle \\ &= \langle g, g \rangle + \langle h, h \rangle = \|g\|_{\mathcal{H}}^2 + \|h\|_{\mathcal{H}}^2 \geq \|g\|_{\mathcal{H}}^2, \\ f(x_i) &= \langle f, k(x_i, \cdot) \rangle = \langle g + h, k(x_i, \cdot) \rangle \quad (\text{再生性}) \\ &= \langle g, k(x_i, \cdot) \rangle + \langle h, k(x_i, \cdot) \rangle = \langle g, k(x_i, \cdot) \rangle = g(x_i). \end{aligned}$$

したがって  $f \notin \mathcal{M}$  なら

$$\lambda \|f\|_{\mathcal{H}}^2 > \lambda \|g\|_{\mathcal{H}}^2,$$

$$L(f(x_1), \dots, f(x_n), b) = L(g(x_1), \dots, g(x_n), b)$$

となるので



$$\begin{aligned} & L(f(x_1), \dots, f(x_n), b) + \lambda \|f\|_{\mathcal{H}}^2 \\ & > L(g(x_1), \dots, g(x_n), b) + \lambda \|g\|_{\mathcal{H}}^2. \end{aligned}$$

よって  $\mathcal{M}$  のなかに最適解が存在する. ■

# 平滑化スプラインとカーネル法

参考：Fasshauer and Ye, Reproducing kernels of Sobolev spaces via a green kernel approach with differential operators and boundary operators, arXiv:1109.5755, 2013.

- スプライン：与えられた点を滑らかにつなぐカーブ。
- 回帰分析への応用：データ点を(ノイズを考慮しつつ)滑らかにつなぐ。





# 平滑化スプライン


学習データ :  $(x_1, y_1), \dots, (x_n, y_n) \in (0, 1) \times \mathbb{R}$ .

モデル :  $y_i = f(x_i) + \varepsilon_i$ ,  $\varepsilon_i$  はノイズ.

- データへのフィッティング :  $\sum_{i=1}^n (y_i - f(x_i))^2 \longrightarrow \text{小さく}$
- 滑らかさ :  $\int_0^1 (f''(x))^2 dx \longrightarrow \text{小さく}$

$$\min_f \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int_0^1 (f''(x))^2 dx \longrightarrow \hat{f}(x)$$

$$\lambda \longrightarrow \infty \implies f(x) = ax + b \text{ (単回帰)}$$



$$n = 50, \quad y = \frac{\sin(4\pi x)}{x} + N(0, 1), \quad x \sim U(0, 1)$$

## 正則化とカーネル関数

- 正則化項  $\int_0^1 (f''(x))^2 dx$  : **RKHS**  $\mathcal{H}_k$  の  $\|f\|^2$  と解釈.

$$L(f) + \lambda \|f\|^2, \quad f \in \mathcal{H}_k \implies \text{表現定理を使って解く}$$

- 対応するカーネル関数を求める.

$$\mathcal{H} = \left\{ \sum_i \beta_i k(x_i, x) : \beta_i \in \mathbb{R}, x_i \in (0, 1) \right\} \text{ (\& 完備化)}$$

$\subset$  適当な **Sobolev** 空間

境界条件 :  $g \in \mathcal{H} \implies$  (極限で)  $g(0) = g'(0) = g(1) = g'(1) = 0$

推定量 :  $f(x) = a + bx + g(x), \quad g \in \mathcal{H}$

- $\mathcal{H}$  の内積.  $\langle f, g \rangle := \langle f'', g'' \rangle_{L_2} = \int_0^1 f''(x)g''(x)dx.$

正則化項:  $\|f\|^2 = \int_0^1 (f'')^2 dx.$

- 境界条件を含めると  $\langle f, f \rangle = 0 \Rightarrow f = 0$  (内積になっている)

再生性が成り立つように  $k$  を定める.  $g \in \mathcal{H}$  に対して

$$\begin{aligned} \langle k_z, g \rangle &= \int_0^1 k_z''(x)g''(x)dx = \left[ g'k_z'' - gk_z''' \right]_0^1 + \int_0^1 g(x)k_z^{(4)}(x)dx \\ &= \int_0^1 g(x)k_z^{(4)}(x)dx \\ \implies \int_0^1 g(x)k_z^{(4)}(x)dx &= g(z) \text{ となってほしい} \end{aligned}$$

## デルタ関数 $\delta$ (物理で登場)

$$\text{関数 } g(x) \text{ に対して } \int_I g(x) \delta(x - z) dx = \begin{cases} g(z), & z \in I, \\ 0, & z \notin I. \end{cases}$$

次式を満たす  $k(x, z) = k_z(x)$  をさがす.

$$\frac{d^4}{dx^4} k_z(x) = \delta(x - z),$$

$$k_z(0) = k'_z(0) = k_z(1) = k'_z(1) = 0.$$


→ 部分積分を使ってどんどん積分すれば求まる

**cf.** 微分作用素  $\frac{d^4}{dx^4}$  のグリーン関数

$$\begin{aligned}
k(x, z) &= \frac{([x - z]_+)^3}{6} + (x, z \text{ の 3 次式}) \quad (\leftarrow \text{境界条件}) \\
&= \frac{([x - z]_+)^3}{6} - \frac{z^3}{6} + \frac{z^2}{2}x + x^2\left(\frac{z^3}{2} - z^2\right) + x^3\left(\frac{z^2}{2} - \frac{z^3}{3}\right), \\
&([a]_+ = \max\{a, 0\}), \quad k(x, z) = k(z, x) \text{ も } \mathbf{O.K.}
\end{aligned}$$

プロット：

$k_z(x)$ ,  $z = 0, 0.2, 0.4, \dots, 1$ .



モデリング：

- $f(x) = a + bx + g(x)$ ,  $g \in \mathcal{H}_k$  で推定. **note:**  $(a + bx)'' = 0$ .
- $a + bx$  で  $f(0), f(1)$  を調整,  $f'(0) = f'(1) = b$ .

スプラインにおける表現定理：

$$\min_f \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int_0^1 (f''(x))^2 dx,$$

$$\text{s.t. } f = a + bx + g(x), \quad g \in \mathcal{H}_k$$

$$\implies \text{最適解 : } \hat{f}(x) = ax + b + \sum_{i=1}^n \beta_i k(x_i, x)$$

自然スプラインは少し違う条件 ( $f''(0) = f''(1)$ ).

*Proof.*  $\mathcal{M} = \text{span}\{k(x_1, \cdot), \dots, k(x_n, \cdot)\}.$

$g \in \mathcal{H}$  を  $g = g_1 + g_2$ ,  $g_1 \in \mathcal{M}$ ,  $g_2 \in \mathcal{M}^\perp$  と分解.

$$\begin{aligned}\sum_{i=1}^n (y_i - f(x_i))^2 &= \sum_{i=1}^n (y_i - a - bx_i - \langle k_{x_i}, g \rangle)^2 \\ &= \sum_{i=1}^n (y_i - a - bx_i - \langle k_{x_i}, g_1 \rangle)^2.\end{aligned}$$

$$\begin{aligned}\int_0^1 (f''(x))^2 dx &= \int_0^1 (g''(x))^2 dx \\ &= \langle g, g \rangle = \langle g_1, g_1 \rangle + \langle g_2, g_2 \rangle \geq \langle g_1, g_1 \rangle.\end{aligned}$$





最適化問題：

$$\min_{a,b,\beta_i} \sum_{i=1}^n \left\{ y_i - a - bx_i - \sum_{j=1}^n \beta_j k(x_j, x_i) \right\}^2 + \lambda \sum_{i,j} \beta_i \beta_j k(x_i, x_j)$$

## 補足：多次元スプラインのカーネル (Matérn kernel)

例.  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ .

$$Af = (\sigma^2 f, \sqrt{2}\sigma f_x, \sqrt{2}\sigma f_y, f_{xx}, \sqrt{2}f_{xy}, f_{yy}), \quad \sigma > 0$$

正則化項 (滑らかさの尺度) :  $\int_{\mathbb{R}^2} \|Af\|_2^2 d\mathbf{x}$

再生性 : 
$$\int_{\mathbb{R}^2} A k_z(\boldsymbol{x}) A g(\boldsymbol{x}) d\boldsymbol{x} = \int_{\mathbb{R}^2} A^* A k_z(\boldsymbol{x}) g(\boldsymbol{x}) d\boldsymbol{x} = g(z).$$

$$A^* A k_z(\boldsymbol{x}) = \delta(\boldsymbol{x} - \boldsymbol{z}), \quad \boldsymbol{x} \in \mathbb{R}^2$$

$$\Leftrightarrow (\sigma^2 - \Delta)^2 k_z(\boldsymbol{x}) = \delta(\boldsymbol{x} - \boldsymbol{z}), \quad \Delta = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}$$

$$\Rightarrow \textbf{Matérn kernel} \quad k(\boldsymbol{x}, \boldsymbol{z}) \propto \frac{\|\boldsymbol{x} - \boldsymbol{z}\|_2}{\sigma} B_1(\sigma \|\boldsymbol{x} - \boldsymbol{z}\|_2)$$

$B_\nu(x)$  : 第II種  $\nu$  次変形ベッセル関数.  
( $\nu$  は次元や微分回数に依存して決まる)

**note:** 1次元スプライン :  $A = \frac{d^2}{dx^2}$ ,  $A^* = \frac{d^2}{dx^2}$ ,  $A^* A = \frac{d^4}{dx^4}$